

S-TEA: Sequential Slow Transfer Learning untuk Pemetaan Kemiskinan dengan Citra Satelit

Rahardi Salim, Christian Yudistira Hermawan, Vincent Davis Leonard Tjoeng, Alfan Farizki Wicaksono

{rahardi.salim, christian.yudistira, vincent.davis}@ui.ac.id, alfan@cs.ui.ac.id}

Corresponding Author: Rahardi Salim

INTISARI — Pemantauan kemiskinan yang akurat dan granular di Indonesia merupakan prasyarat fundamental untuk perencanaan pembangunan yang efektif, namun terhambat oleh keterbatasan data survei konvensional yang mahal, berfrekuensi rendah, dan tidak representatif pada tingkat administrasi yang lebih rendah. Penelitian ini bertujuan mengembangkan kerangka kerja inovatif S-TEA (*Sequential Slow Transfer Learning*) untuk memprediksi tingkat kemiskinan kecamatan menggunakan data citra satelit dan geospasial yang tersedia publik. Metodologi mengadopsi strategi *sequential fine-tuning* berdasarkan konsep *slow learner*, di mana model *Convolutional Neural Network* yang telah melalui pra-pelatihan dilatih secara berurutan pada tugas proksi klasifikasi intensitas *Night-time Lights*, *Normalized Difference Vegetation Index*, dan *Land Surface Temperature* untuk membangun representasi fitur multidimensi sambil memitigasi *catastrophic forgetting*. Fitur visual yang diekstraksi kemudian digabungkan dengan fitur geospasial untuk melatih model prediksi menggunakan algoritma *gradient boosting*. Hasil penelitian menunjukkan kerangka kerja S-TEA mampu memitigasi *catastrophic forgetting* dengan penurunan $CPCF_j$ relatif hingga 81,5% pada konfigurasi terbaik dibandingkan *baseline*, membuktikan efektivitas pendekatan *sequential learning* multi-proksi dalam menghasilkan peta kemiskinan beresolusi tinggi yang mendukung perencanaan pembangunan yang lebih tepat sasaran di Indonesia.

KATA KUNCI — Pemetaan Kemiskinan, *Transfer Learning*, Citra Satelit, *Sequential Fine-Tuning*, *Slow Learner*

I. PENDAHULUAN

Kebutuhan akan data kemiskinan yang akurat dan memiliki resolusi spasial tinggi belum sepenuhnya dipenuhi oleh Survei Sosial Ekonomi Nasional (Susenas). Namun, survei ini menghadapi tantangan signifikan seperti biaya tinggi, jeda publikasi data yang lama, serta kekuatan sampel yang tidak memadai untuk estimasi kemiskinan di level granula [2, 3, 15]. Dari keterbatasan ini, eksplorasi sumber data alternatif, seperti citra satelit dan fitur-fitur geospasial, menjadi sangat krusial karena menawarkan perbaruan pada resolusi yang lebih tinggi [7, 12].

Latar Belakang. Metodologi prediksi kemiskinan sudah berkembang; dari pendekatan awal yang diperkenalkan oleh [7], memanfaatkan metode *transfer learning* pada *Convolutional Neural Network* (**CNN**) untuk memprediksi *Night-time Lights* (**NTL**) dari citra satelit di siang hari. Metode ini mengintegrasikan teknik regresi *machine learning* konvensional dengan memanfaatkan fitur geospasial, seperti rata-rata **NTL**, populasi dan variabel agregat lainnya [12]. Pendekatan ini memperkenalkan baseline yang baik, namun juga memiliki keterbatasan karena modelnya hanya belajar di satu proksi yaitu **NTL**. Sementara itu, ekstensi pendekatan kedua belum memiliki detail geospasial yang dapat diekstraksi dari citra mentah.

Kontribusi	STAN	THAI	S-TEA
Lokasi	Afrika	Thailand	Indonesia
Ekstraksi citra	✓	✗	✓
Tabular Geospatial	✗	✓	✓
Sequential	✗	✗	✓
SL	✓	✗	✓
Hybrid SL	✗	✗	✓

TABEL I. POSISI PENELITIAN INI DIBANDINGKAN PENELITIAN TERKAIT. **STAN** MERUJUK PADA PEKERJAAN OLEH JEAN DKK. [7] DAN **THAI** OLEH PUTTANAPONG DKK. [12].

Penelitian ini mengusulkan **S-TEA**, kerangka kerja yang terin-

spirasi dari *continual learning*. Pendekatan ini mengatasi isu *catastrophic forgetting* [8] yang memampukan model belajar tanpa melupakan pengetahuan sebelumnya. Pada tabel I dapat dilihat bahwa pendekatan **S-TEA** mampu mengungguli beberapa aspek dari segi lokasi data geospasial, kemampuan mengekstraksi citra dan tabular, serta menerapkan metode *Hybrid Slow Learning*. *Hybrid SL* mengakomodasi pendekatan *sequential fine-tuning* dengan penyesuaian plastisitas lanjut yang memungkinkan model mempelajari fitur-fitur relevan dari berbagai proksi geospasial. Kontribusi penelitian ini memperkenalkan pendekatan baru yang mengatasi isu ketersediaan data dan secara praktis mendukung upaya penanggulangan kemiskinan granular di Indonesia.

Tujuan, Manfaat, dan Kontribusi. Kontribusi utama penelitian ini adalah inovasi metodologis **S-TEA** yang pertama kali menerapkan strategi *slow learner* pada pembelajaran sekuel-sial multi-proksi (**NTL**, **NDVI**, **LST**) dan mengoptimalkan fusi fitur *deep learning* tabular, serta menjadi aplikasi pertama dari pendekatan ini pada skala nasional di Indonesia. Secara praktikal, **manfaat** yang dihasilkan adalah tersedianya alat pemetaan kemiskinan yang lebih granular dan *cost effective*. Alat ini mendukung pemerintah dalam merancang penanggulangan kemiskinan yang lebih tepat sasaran dan berbasis data. Pengembangan **S-TEA** juga merupakan kontribusi nyata kami dalam bidang “penambangan data dalam rangka meningkatkan TIK menuju kemandirian bangsa”.

Batasan. Sumber data pada penelitian ini berasal dari tahun 2015 dengan cakupan geografis di tingkat kecamatan seluruh Indonesia. Fokus metodologisnya adalah pada pengembangan dan validasi kerangka kerja **S-TEA**, dengan data survei kemiskinan *SMERU* 2015 digunakan sebagai *ground truth*.

II. KAJIAN PUSTAKA

Poverty Mapping Berbasis Transfer Learning. Sebuah paradigma yang dipelopori oleh Xie dkk. [16] memperke-

nalkan penggunaan *Convolutional Neural Networks (CNN)* untuk ekstraksi fitur secara otomatis langsung dari piksel citra satelit mentah [7, 16]. Metodologi ini melibatkan pra-pelatihan **CNN** pada **ImageNet**, *Fine-tuning* dengan prediksi intensitas **NTL**, dan ekstraksi untuk prediksi indikator kemiskinan menggunakan model regresi sederhana [7]. Metode ini memiliki kelemahan pada tahap agregasi, karena prosesnya merata-ratakan vektor untuk memperoleh satu representasi tunggal bagi seluruh kecamatan. Pendekatan tersebut berpotensi menghilangkan konteks global yang terkandung dalam data, sehingga dapat mengurangi ketepatan hasil prediksi.

Poverty Mapping dengan Geospatial Features. Pendekatan lanjutan yang menggunakan model *machine learning* konvensional dengan fitur geospasial terstruktur seperti intensitas **NTL**, kepadatan jalan, dan *Points of Interest (POI)* [12] menghadapi dua kendala utama. Pertama, kualitasnya terdegradasi oleh heterogenitas spasial data. Sementara itu, data yang bersumber dari **OpenStreetMap** (OSM) jauh lebih lengkap di area perkotaan. Hal ini menyebabkan bias sistemik yang berisiko menghasilkan hubungan yang semu [11, 14]. Selain itu, keterbatasan lainnya adalah hilangnya informasi spasial dari agregasi fitur akibat saturasi metodenya. Kehilangan detail ini merupakan kelemahan inheren dari metode berbasis agregasi, sebuah tantangan yang coba diatasi oleh paradigma *deep learning* yang mampu mengekstraksi fitur-fitur kompleks tersebut langsung dari citra mentah [17].

Catastrophic Forgetting (CF). Pelatihan *deep learning* secara sekuensial menghadapi CF. CF merupakan situasi di mana model melupakan konteks lama ketika sudah mempelajari tugas baru [4, 8]. Secara umum, akar permasalahannya terletak di dilema stabilitas-plastisitas [1], yang berarti model tidak secara seimbang mempertahankan pengetahuan (stabilitas) bersamaan dengan data baru (plastisitas).

Hybrid Slow Learner (Hybrid SL). Pendekatan “*Slow Learner*” (SL) [18] mengatasi dilema stabilitas-plastisitas tanpa modifikasi arsitektur atau penyimpanan data lama. SL menerapkan laju pembelajaran ganda: sangat rendah (α) pada lapisan *backbone* untuk stabilitas fitur, dan tinggi (β) pada lapisan *head* untuk plastisitas tugas baru. Karena *fine-tuning* keseluruhan *backbone* SL mahal secara komputasi, *Hybrid Slow Learner* mengatasi sebagai varian *parameter-efficient* yang mengadaptasi model dengan jejak memori minimal melalui modul seperti LoRA [6].

III. METODOLOGI

A. DATASET

Citra Satelit Sentinel-2. Data utama penelitian ini menggunakan citra Sentinel-2 Level-2A (*Surface Reflectance*) dari program Copernicus. Untuk setiap kecamatan, dibuat komposit multitemporal periode 2015 – 2019 dengan resolusi spasial 10 meter melalui tahapan: (1) filtering awan dan bayangan menggunakan *Scene Classification Layer*, (2) agregasi median untuk mengurangi *noise* temporal, dan (3) pembagian menjadi *tile* 224×224 piksel.

Penelitian ini menggunakan dua skala fitur: yaitu tingkat kecamatan untuk model akhir dan tingkat *tile* untuk *pre-training CNN*. Fitur pada tingkat kecamatan diperoleh dari **Google Earth Engine** dan **OpenStreetMap**, kemudian diagregasi berdasarkan batas poligon masing-masing kecamatan (Tabel II). Untuk fitur tingkat *tile*, setiap *tile* diberi label kelas berdasarkan nilai geospasial di piksel pusat untuk *sequential fine-tuning CNN* (Tabel III).

Kategori	Variabel	Sumber Data
Data Raster (Kontinu)	NTL (rata-rata)	NOAA/VIIRS
	NDVI (rata-rata)	MODIS/MOD13A1
	LST (rata-rata)	MODIS/MOD11A1
	Curah hujan (akumulasi)	UCSB-CHG/CHIRPS
	Populasi (rata-rata)	WorldPop
Data Raster (Kategorikal)	GHSL (proporsi kelas)	Global Human Settle.
	ESA Land Cover (proporsi)	COPERNICUS
	USGS Land Cover (proporsi)	MODIS/MCD12Q1
	WSF (proporsi terbangun)	World Settle. Footprint
Infrastruktur (OSM)	Panjang Jalan (total km) Jumlah POI (total)	OpenStreetMap

TABEL II. FITUR TINGKAT KECAMATAN

Variabel	Kelas	Kriteria
NTL	0 (Gelap)	Intensitas $< 0,2$
	1 (Redup)	$0,2 \leq$ Intensitas $\leq 1,0$
	2 (Terang)	Intensitas $> 1,0$
NDVI/LST	0 (Rendah)	Kuartil ke-1 (0 – 33%)
	1 (Sedang)	Kuartil ke-2 (34 – 66%)
	2 (Tinggi)	Kuartil ke-3 (67 – 100%)

TABEL III. SKEMA PELABELAN TILE

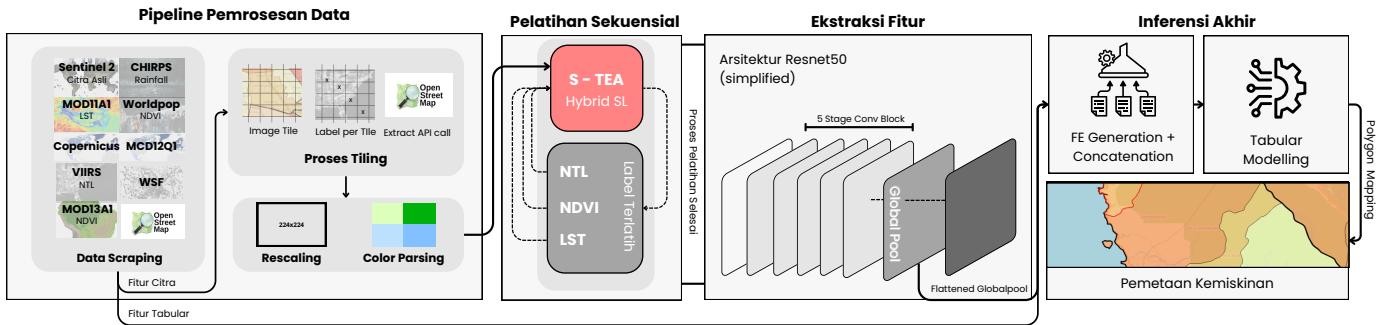
Partisi Data	# Kecamatan	# Tile Citra
Training	502	3.758
Validasi	169	917
Testing	171	1.374
Total	842	6.049

TABEL IV. DISTRIBUSI TILE CITRA HASIL SAMPLING PER KECAMATAN

Sampling dan Pembagian Data. Sebanyak 842 kecamatan dipilih melalui sampling acak dari lima strata yang dibentuk menggunakan equal-width binning pada nilai FGT0 NPL. Sampel kecamatan ini kemudian dipartisi menjadi set training (60%), validasi (20%), dan testing (20%) secara terstratifikasi. Distribusi data disampaikan pada Tabel IV.

B. SEQUENTIAL TRAINING

Sequential Learning. Pendekatan ini mengimprovisasi *transfer learning* dalam pemetaan kemiskinan yang dipelopori oleh Jean dkk. [7]. Paradigma tersebut melibatkan *fine-tuning* sebuah **CNN** pada tugas memprediksi intensitas **NTL**. Namun, **S-TEA** secara fundamental berbeda karena menggunakan kerangka kerja sekuensial multi-proksi (**NTL**, **NDVI**, **LST**). Model dilatih secara sekuensial pada tiga tugas klasifikasi dengan urutan yang tetap: **NTL** \rightarrow **NDVI** \rightarrow **LST**. Untuk setiap tugas proksi T_k , nilai geospasial kontinu didiskritisasi menjadi tiga kelas ($C_k \in \{0, 1, 2\}$) berdasarkan diskretisasi tahap sebelumnya.



GAMBAR 1. Pipeline Penelitian STEA untuk Pemetaan Kemiskinan. (1) **Pemrosesan Data:** Citra satelit multi-sumber (Sentinel-2, MODIS, VIIRS) diproses menjadi tile 224x224 piksel dengan label proksi geospasial (NTL, NDVI, LST). Data tabular (OpenStreetMap) diproses terpisah. (2) **Pelatihan Sekuensial:** ResNet-50 pra-latih ImageNet diadaptasi menggunakan strategi **S-TEA** (Hybrid Slow Learner), dilatih berurutan pada tiga tugas proksi (NTL → NDVI → LST). (3) **Ekstraksi Fitur:** ResNet backbone dengan GlobalMaxPooling mengekstrak embedding dari setiap tile citra. (4) **Inferensi Akhir:** Embedding visual diagregasi per kecamatan dan digabung dengan fitur tabular, kemudian digunakan model tabular untuk prediksi tingkat kemiskinan final.

C. HYBRID SLOW LEARNER

Kerangka kerja **S-TEA** mengimplementasikan strategi **Hybrid Slow Learner**, sebuah pendekatan *fine-tuning* yang sangat terkontrol untuk mengadaptasi model pra-pelatihan pada serangkaian tugas proksi sekuensial (T_1, T_2, \dots, T_K). Inti dari metodologi ini terletak pada dua pilar: arsitektur adaptif secara parameter dan strategi optimisasi multi-rate. (Gambar 2)

Hybrid LoRA. Alih-alih melakukan *fine-tuning* pada seluruh parameter *backbone* θ_b , kami menerapkan strategi *hybrid*. Bobot inti dari lapisan konvolusi ($\theta_{b,\text{core}}$) sepenuhnya dibukukan untuk menjaga stabilitas representasi. Adaptasi hanya dilakukan pada dua jenis parameter:

- 1) **Parameter Efisien ($\theta_{b,\text{eff}}$):** Parameter *bias* dan bobot *batch normalization* (γ, β) di seluruh *backbone*; dan
- 2) **Parameter Adaptasi LoRA (θ_{lora}):** Matriks dekomposisi berperingkat rendah yang diinjeksikan ke dalam lapisan *fully-connected* setelah *global pooling*.

Untuk sebuah matriks bobot pra-pelatihan $W_0 \in \mathbb{R}^{d_2 \times d_1}$ pada lapisan yang diadaptasi, pembaruan bobotnya dibatasi oleh *Low-Rank Adaptation* (LoRA) [6]:

$$W_{\text{adapted}} = W_0 + \alpha \cdot BA,$$

dengan $B \in \mathbb{R}^{d_2 \times r}$ dan $A \in \mathbb{R}^{r \times d_1}$ adalah matriks adaptasi yang dapat dilatih dengan rank $r \ll \min(d_1, d_2)$.

Inisialisasi LoRA berbasis SVD. Untuk memastikan adaptasi yang stabil dari domain umum ke citra satelit, kami menginisialisasi matriks LoRA menggunakan dekomposisi nilai singular (SVD) dari $W_0 = U\Sigma V^T$:

$$\begin{aligned} A_{\text{init}} &= V_{1:r,:}^T \quad (\text{diambil dari top-}r \text{ baris } V^T), \\ B_{\text{init}} &= \mathbf{0}_{d_2 \times r} \quad (\text{diinisialisasi sebagai matriks nol}). \end{aligned}$$

Inisialisasi ini memastikan bahwa pada awal pelatihan, $\Delta W = BA = 0$, sehingga model memulai adaptasi dari titik yang identik dengan bobot pra-pelatihan.

Optimisasi Multi-Rate dengan SCE. Untuk menyeimbangkan gradien pembelajaran antara sampel yang mudah dan

sulit, pelatihan model menggunakan fungsi kerugian *Symmetric Cross-Entropy (SCE)* [18]. Berbeda dengan *Cross-Entropy* (CE) standar yang cenderung didominasi oleh sampel-sampel sulit (dengan kepercayaan rendah), SCE menambahkan komponen *Reverse Cross-Entropy (RCE)* untuk menstabilkan proses pelatihan. Hal ini sangat penting dalam pembelajaran sekuensial untuk mencegah *overfitting* pada tugas-tugas baru. Proses optimisasi kemudian menerapkan prinsip *Slow Learner* melalui skema **laju pembelajaran multi-rate**. Tujuannya adalah untuk menyeimbangkan **stabilitas** (kemampuan mengingat tugas lama) dan **plastisitas** (kemampuan mempelajari tugas baru) dengan memberikan kecepatan belajar yang berbeda pada setiap kelompok parameter. Aturan pembaruan untuk setiap kelompok parameter $\theta^{(i)}$ mengikuti kaidah *gradient descent*:

$$\theta_{t+1}^{(i)} = \theta_t^{(i)} - \eta_i \nabla_{\theta^{(i)}} \mathcal{L}_{\text{SCE}},$$

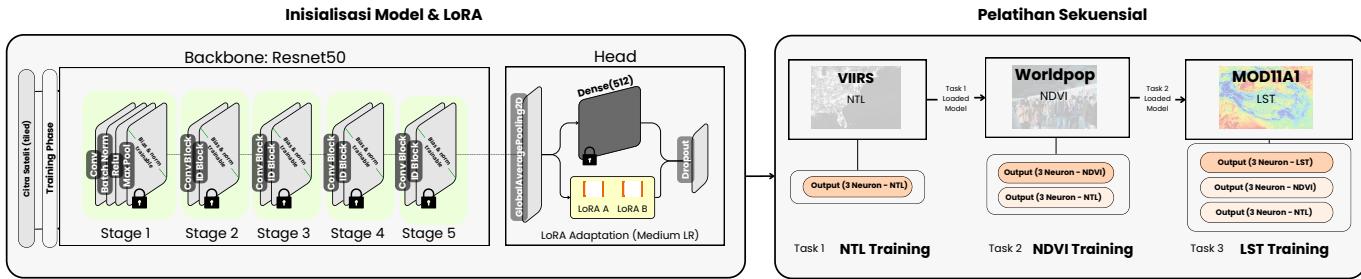
$\theta^{(i)}$ merujuk pada salah satu dari tiga kelompok parameter berikut, yang diurutkan dari yang tercepat hingga terlambat:

- **Classification Head (θ_{head}):** Dilatih dengan laju pembelajaran **tertinggi** (η_{head}) untuk beradaptasi secara cepat dengan kelas-kelas pada tugas baru (plastisitas tinggi).
- **Parameter LoRA (θ_{lora}):** Menggunakan laju pembelajaran **menengah** (η_{lora}) untuk adaptasi yang terkontrol.
- **Parameter Efisien ($\theta_{b,\text{eff}}$):** Dilatih dengan laju pembelajaran **terendah** (η_{eff}) untuk menjaga pengetahuan inti yang tersimpan di *backbone* (stabilitas tinggi).

Seiring dengan pengenalan tugas proksi baru secara sekuensial, arsitektur *classification head* ($h_{\theta_{\text{head}}}$) diperluas secara dinamis untuk mengakomodasi himpunan kelas yang bertambah, di mana dimensi outputnya menjadi $D_{\text{out}}^{(k)} = |\bigcup_{i=1}^k C_i|$.

D. AGREGASI FITUR DAN MODEL PREDIKSI FINAL

Setelah proses *fine-tuning* selesai, *backbone* $f_{\theta_b^*}$ yang telah diperkaya digunakan sebagai ekstraktor fitur. Untuk setiap kecamatan, fitur visual dari semua *tile* citra diagregasi melalui *mean pooling* ($v_{\text{kec}} = \frac{1}{N} \sum f_{\theta_b^*}(x_i)$). Vektor visual ini kemudian digabungkan dengan fitur geospasial tabular (z_{kec}) untuk membentuk vektor fitur *hybrid*, $h_{\text{kec}} = [v_{\text{kec}} \oplus z_{\text{kec}}]$.



GAMBAR 2. Ilustrasi arsitektur Hybrid Slow Learner. Menunjukkan bagaimana parameter model dibagi menjadi beberapa grup (inti beku, efisien, LoRA, dan head) yang masing-masing dioptimalkan dengan laju pembelajaran berbeda untuk menyeimbangkan stabilitas dan plastisitas.

Terakhir, LightGBM, XGBoost, dan CatBoost, dilatih pada fitur *hybrid* ini untuk memprediksi indikator kemiskinan.

E. METRIK EVALUASI

Untuk mengukur *catastrophic forgetting* secara kuantitatif, penelitian ini menggunakan metrik *Conformal Prediction Confidence Factor (CPCF)* [9]. Metrik $CPCF_j$ dihitung setelah model dilatih pada tugas baru (tugas ke- j), dan didefinisikan sebagai **rata-rata ukuran himpunan prediksi (prediction set)** pada seluruh data uji dari semua tugas yang telah dipelajari sebelumnya.

$$CPCF_j = \frac{1}{|\mathcal{X}_t^{1:j-1}|} \sum_{x_t \in \mathcal{X}_t^{1:j-1}} |\mathcal{C}(x_t)|,$$

dengan $\mathcal{X}_t^{1:j-1}$ adalah himpunan seluruh sampel uji dari tugas 1 hingga $j - 1$; $|\mathcal{X}_t^{1:j-1}|$ adalah jumlah total sampel uji dari tugas-tugas sebelumnya; $\mathcal{C}(x_t)$ adalah himpunan prediksi (*prediction set*) untuk sebuah sampel uji x_t ; dan $|\mathcal{C}(x_t)|$ adalah panjang (jumlah elemen) dari himpunan prediksi tersebut.

Nilai $CPCF_j$ yang lebih rendah mengindikasikan kepercayaan model yang lebih tinggi dan retensi pengetahuan yang lebih baik, sedangkan nilai yang lebih tinggi menunjukkan peningkatan ketidakpastian dan potensi terjadinya *catastrophic forgetting*. Sementara itu, untuk mengukur performa model dalam melakukan inferensi kemiskinan, digunakan dua metrik utama: Koefisien Determinasi R^2 dan *Explained Variance Score*. Kedua metrik ini mengevaluasi seberapa baik model dapat menjelaskan varians pada data target.

IV. HASIL EKSPERIMEN

A. MITIGASI CATASTROPHIC FORGETTING

Tabel V menunjukkan superioritas Hybrid Slow Learner dalam memitigasi *catastrophic forgetting*. Metode yang diusulkan secara konsisten mencapai nilai $CPCF_j$ terendah di semua konfigurasi eksperimen, dengan performa terbaik pada $IE = 10, TE = 20$ ($CPCF_j$: 1,05 untuk Seq 2, 1,46 untuk Seq 3). Dibandingkan baseline Non-SL yang mencapai $CPCF_j$ hingga 7,40, Hybrid SL menunjukkan peningkatan stabilitas yang signifikan, dengan penurunan $CPCF_j$ relatif terhadap Non SL hingga 81,5% pada konfigurasi $IE = 5, TE = 10$, Seq 2, serta

Epoch	Train Seq	$CPCF_j$		
		Non SL	SL	Hybrid SL
IE = 5, TE = 10	Seq 2	6,12	4,30	1,13
	Seq 3	7,40	5,20	2,76
IE = 5, TE = 20	Seq 2	4,73	5,58	1,26
	Seq 3	7,44	6,75	3,23
IE = 10, TE = 20	Seq 2	3,00	5,70	1,05
	Seq 3	3,95	6,28	1,46
IE = 5, TE = 30	Seq 2	5,41	5,77	1,05
	Seq 3	7,27	7,43	1,23
IE = 10, TE = 30	Seq 2	4,41	5,52	1,16
	Seq 3	6,73	6,32	3,13

TABEL V. HASIL EVALUASI MODEL. DIMULAI DARI SEQUENCE 2 UNTUK MENGUKUR CATASTROPHIC FORGETTING. IE: INITIAL EPOCH, TE: TOTAL EPOCH

konsisten mempertahankan $CPCF_j$ terendah di semua konfigurasi eksperimen (Tabel V). Hasil ini mengkonfirmasi efektivitas strategi optimisasi multi-rate dalam menyeimbangkan dilema stabilitas-plastisitas.

B. PERFORMA PREDIKSI KEMISKINAN

Tabel VI kinera model dalam memprediksi kemiskinan. Kombinasi LightGBM dengan SL Hybrid Sequential mencapai performa tertinggi dengan $R = 0,593$ dan *ExplainedVariance* = 0,597, mampu menjelaskan hampir 60% variasi kemiskinan tingkat kecamatan.

Kontribusi Metodologis. Perbandingan sistematis menunjukkan: (1) Pembelajaran sekuensial meningkatkan performa 3,9 – 10,4 poin dibanding non-sequential, (2) Hybrid approach memberikan gain tambahan 2,2 – 5,7 poin dibanding SL standar, dan (3) Mitigasi *catastrophic forgetting* berkontribusi 4,6 – 9,4 poin peningkatan performa.

V. ANALISIS

Hasil evaluasi pada Tabel V membuktikan superioritas strategi *Hybrid Slow Learner* (Hybrid SL) dalam memitigasi *catastrophic forgetting*. Hybrid SL konsisten mencatat skor $CPCF_j$ terendah di semua konfigurasi eksperimen, melampaui performa metode *Slow Learner* (SL) standar dan Non-SL. Keunggulan ini dicapai melalui strategi pembekuan *backbone*

Model Regresi	Metode Eksperimen					
	SL Hybrid Sequential	SL Hybrid Non-Sequential	SL Sequential	SL	No SL Sequential	No SL
Skor R²						
LightGBM	0,593	0,565	0,536	0,551	0,499	0,554
XGBoost	<u>0,439</u>	0,551	0,567	0,543	0,489	0,533
CatBoost	0,533	0,556	0,536	0,550	0,547	0,504
Skor Explained Variance						
LightGBM	0,597	0,574	0,545	0,551	0,508	0,555
XGBoost	<u>0,449</u>	0,555	0,570	0,546	0,491	0,536
CatBoost	0,533	0,557	0,536	0,550	0,551	0,504

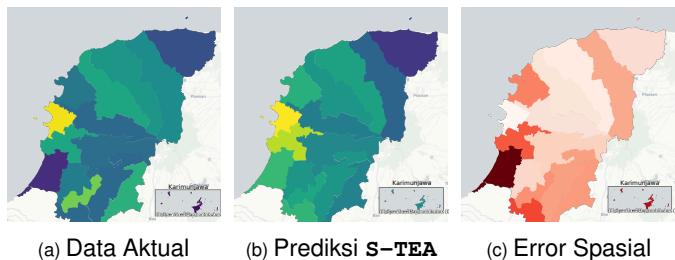
TABEL VI. PERBANDINGAN KINERJA MODEL BERDASARKAN METODE EKSPERIMENT. **BOLD** MENUNJUKKAN SKOR TERBAIK PER MODEL, UNDERLINE MENUNJUKKAN SKOR TERBAIK KESELURUHAN.

dan adaptasi parameter efisien yang mencegah pergeseran representasi fitur drastis—sebuah masalah kritis mengingat tingginya korelasi antar fitur proksi (**NTL**, **NDVI**, **LST**).

Temuan menarik menunjukkan bahwa pada beberapa skenario, metode SL standar justru berkinerja lebih buruk daripada Non-SL karena perubahan kecil yang terakumulasi dapat mengganggu representasi fitur pada tugas berkorelasi tinggi. Hal ini menegaskan pentingnya pendekatan Hybrid SL yang lebih selektif dalam mengadaptasi parameter.

Stabilitas fitur yang dihasilkan berdampak langsung pada kinerja prediksi kemiskinan. Seperti yang ditunjukkan pada Tabel VI, kombinasi SL Hybrid Sequential dengan model regresi LightGBM menghasilkan performa terbaik ($R^2 = 0,593$, *Explained Variance* = 0,597), menunjukkan bahwa representasi fitur yang stabil dan kaya merupakan fondasi yang kuat untuk model prediksi akhir.

Untuk memvalidasi hasil kuantitatif tersebut, analisis spasial dilakukan pada wilayah uji Kabupaten Jepara, Jawa Tengah. Korespondensi yang kuat antara prediksi model **S-TEA** dan data kemiskinan aktual dapat diamati pada Gambar 3.



GAMBAR 3. Perbandingan spasial tingkat kemiskinan Kabupaten Jepara: Warna hijau menunjukkan tingkat kemiskinan, warna merah menunjukkan tingkat error—semakin gelap, semakin tinggi nilainya.

Peta prediksi **S-TEA** (Gambar 3b) berhasil menangkap pola distribusi kemiskinan aktual dengan korelasi kuat ($R^2 = 0,593$). Namun, peta residual spasial (Gambar 3c) mengungkap keterbatasan model pada wilayah dengan karakteristik ekonomi unik, terutama di area pesisir.

Kecamatan Kedung, Jepara, menunjukkan error tinggi karena dominasi ekonomi tambak yang menciptakan sinyal geospasial ambigu. Karakteristik unik ini meliputi **NDVI** rendah dari permukaan air tambak, pola suhu permukaan **LST** yang

berbeda dari daratan, dan pola lampu malam **NTL** yang tidak sesuai dengan asumsi model konvensional [5, 7, 17]. Struktur ekonomi pesisir yang kompleks, eksistensi tambak, dan industri pengolahan—serta faktor sosial tidak dapat ditangkap secara optimal oleh proksi satelit standar [10, 13].

Keberhasilan **S-TEA** terletak pada sinergi komponennya, di mana mitigasi aktif *catastrophic forgetting* melalui Hybrid SL menghasilkan fitur yang stabil dan representatif untuk pemetaan kemiskinan. Meskipun terdapat keterbatasan pada wilayah dengan karakteristik ekonomi lokal yang unik, performa keseluruhan sistem menunjukkan potensi yang menjanjikan untuk aplikasi pemetaan kemiskinan skala besar.

VI. KESIMPULAN

Kerangka kerja **S-TEA** yang diusulkan dalam penelitian ini mengimplementasikan *Hybrid Slow Learner*, dalam hal ini telah menunjukkan kemampuannya dalam membangun kestabilan antara plasticitas dan stabilitas dalam pembelajaran sekuensial. Performa **S-TEA** mampu mengungguli pendekatan sekuensial konvensional yang dibuktikan pada performa model yang hasil ekstraksi fiturnya dikombinasikan dengan model regresi *LightGBM*, yang berhasil mencapai skor R^2 sebesar 0,593. Dibandingkan dengan pendekatan konvensional dan SL biasa, metode ini terbilang berhasil dalam memitigasi *catastrophic forgetting* hingga 81,5% dibandingkan *baseline*. Hal ini mengonfirmasi bahwa strategi pelatihan yang menjaga stabilitas *backbone* secara eksplisit merupakan prasyarat optimal dalam mengekstraksi fitur yang *meaningful* dari data yang memiliki korelasi tinggi.

S-TEA juga menjawab urgensi tinggi dalam konteks permasalahan di Indonesia, di mana perencanaan pembangunan masih sangat bergantung pada data survei periodik seperti Susenas yang memiliki keterbatasan dalam hal biaya, frekuensi dan resolusi spasial. Melalui kontribusi dari data citra satelit, **S-TEA** menjadi salah satu solusi untuk mengatasi kesenjangan tersebut. Dengan demikian, penelitian ini memberikan bukti empiris bahwa pendekatan **S-TEA** berpotensi menjadi alat bantu yang mampu untuk berkontribusi secara langsung dalam membantu penanggulangan kemiskinan di Indonesia, serta mendorong kemandirian bangsa ini dengan meningkatkan pengaplikasian TIK yang aplikatif.

REFERENSI

- [1] W. C. Abraham dan A. Robins. Memory retention—the synaptic stability versus plasticity dilemma. *Trends in neurosciences*, 28(2):73–78, 2005.
- [2] Badan Pusat Statistik (BPS). Rencana kerja dan anggaran badan pusat statistik. Technical report, BPS, Jakarta, 2024.
- [3] Badan Pusat Statistik (BPS). Statistik kemiskinan indonesia, september 2024. Technical report, BPS, Jakarta, 2025.
- [4] Z. Chen dan B. Liu. Lifelong machine learning. *Synthesis Lectures on Artificial Intelligence and Machine Learning*, 12(3):1–207, 2018.
- [5] R. Engstrom, J. Hersh, dan D. Newhouse. Poverty from space: Using high-resolution satellite imagery for estimating economic well-being. *The World Bank Economic Review*, 34(3):592–611, 2017. doi: 10.1093/wber/lhx042. URL <https://openknowledge.worldbank.org/entities/publication/4d2d0726-ee6e-505d-a278-e36de797787d>.
- [6] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, dan W. Chen. Lora: Low-rank adaptation of large language models, 2021.
- [7] N. Jean, M. Burke, M. Xie, W. M. Davis, D. B. Lobell, dan S. Ermon. Combining satellite imagery and machine learning to predict poverty. *Science*, 353(6301):790–794, 2016.
- [8] G. I. Parisi, R. Kemker, J. L. Part, C. Kanan, dan S. Wermter. Continual lifelong learning with neural networks: A review. *Neural Networks*, 113:54–71, 2019.
- [9] I. Pitsiorlas, N. Jamoussi, dan M. Kountouris. A conformal predictive measure for assessing catastrophic forgetting. *arXiv preprint arXiv:2505.10677*, 2025.
- [10] N. Pokhriyal dan D. C. Jacques. Combining disparate data sources for improved poverty prediction and mapping. *Proceedings of the National Academy of Sciences*, 114(46):E9783–E9792, 2017.
- [11] A. Psyllidis dkk. Points of interest (poi): a commentary on the state of the art, challenges, and prospects for the future. *Computational Urban Science*, 2(1):20, 2022.
- [12] N. Puttanapong, A. Martinez, J. A. N. Bulan, dan M. Martillan. Predicting poverty using geospatial data in thailand. *ISPRS International Journal of Geo-Information*, 11(5):293, 2022.
- [13] M. Rodriguez, J. Thompson, dan S. Lee. Spatial auto-correlation in satellite-based poverty mapping: challenges and solutions. *Remote Sensing of Environment*, 285: 113401, 2023.
- [14] D. Sulistioningrum dkk. Openstreetmap sebagai alternatif teknologi dan sumber data pemetaan desa inovasi untuk percepatan pemetaan desa. ResearchGate, 2019.
- [15] The SMERU Research Institute. Peta Kemiskinan Indonesia 2015: Deskripsi dan Analisis. Technical report, The SMERU Research Institute, Jakarta, Indonesia, 2015.
- [16] M. Xie, N. Jean, M. Burke, D. Lobell, dan S. Ermon. Transfer learning from deep features for remote sensing and poverty mapping. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 30, 2016.
- [17] C. Yeh, A. Perez, A. Driscoll, G. Azzari, Z. Tang, D. Lobell, S. Ermon, dan M. Burke. Using publicly available satellite imagery and deep learning to understand economic well-being in africa. *Nature Communications*, 11(1):2583, 2020.
- [18] T. Zhang dkk. Slca: Slow learner with classifier alignment for continual learning on a pre-trained model. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2024.